우주전파재난 AI 경진대회 개발모델 개요서

□ **참가팀**

팀명	AJAI
팀원 성명	남기현, 전준서(총 2명)
소속	아주대학교 전자공학과

□ **모델 개발 개요서**

1. 데이터 셋 구성

1) 주어진 데이터 셋

- ACE, DSCOVR 위성 데이터의 태양풍 데이터
- 국내 지자기 관측소 3곳의 지구자기장 관측 데이터

"Kp는 미국 NOAA SWPC(Space Weather Prediction Center)에서 위도 44 – 60도 사이의 ***8개 지자기 관측소***에서의 구한 K 지수를 통합하여 산출하고 있다."[1]

우주전파센터 홈페이지의 Kp지수 관련 내용에서 "8개 지자기 관측소" 를 가지고 Kp지수를 계산한다고 명시되어 있으므로 ACE, DSCOVR 위성 데이터의 태양풍 데이터는 사용하지 않고 국내 지자기 관측소 3곳의 지구자기장 관측 데이터만을 사용

2) 데이터 셋 전처리

2) - 1. 데이터 보간

```
GGG_df[['X','Y','Z']] = GGG_df[['X','Y','Z']].interpolate(method='linear', limit=5)
GGI_df[['X','Y','Z']] = GGI_df[['X','Y','Z']].interpolate(method='linear', limit=5)
GGJ_df[['X','Y','Z']] = GGJ_df[['X','Y','Z']].interpolate(method='linear', limit=5)
```

결측치가 있는 부분에 선형보간을 적용함.

(단, 연속적으로 매우 길게 결측치가 형성되어 있는 경우 선형 보간을 할 시 오차가 커지므로 threshold를 5로 지정함.)

2) - 2. 입력데이터 셋

지역	데이터	데이터형		데이터형
강릉	Bx	4207680	변환	(23376, 180, 3)
	By	4207680		
	Bz	4207680		
이천	Bx	4207680		(23376, 180, 3)
	By	4207680		
	Bz	4207680		
제주	Bx	4207680		(23376, 180, 3)
	By	4207680		
	Bz	4207680		

2) - 3. 출력 데이터 셋

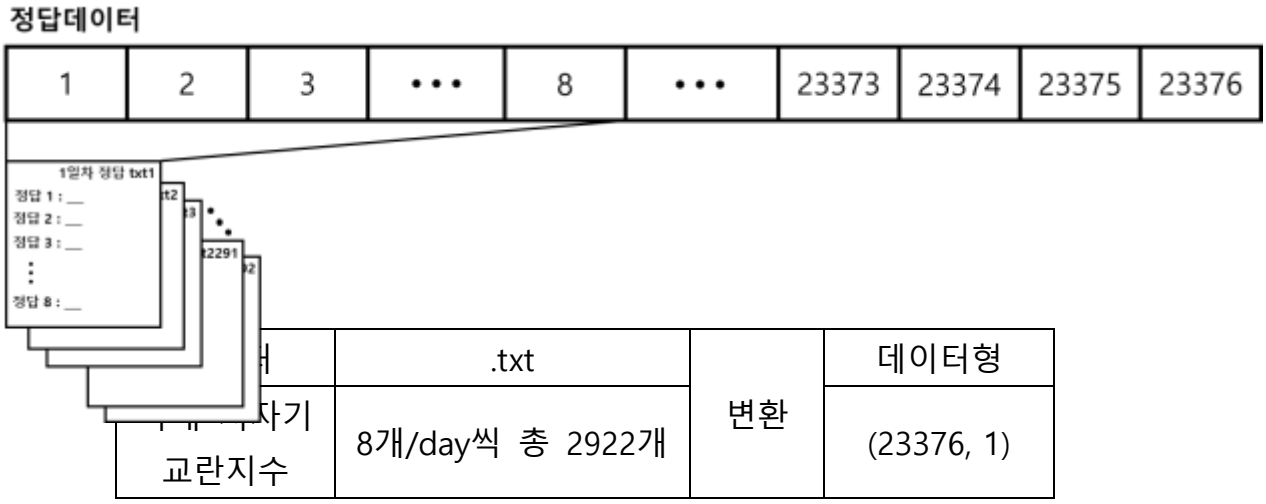

	.txt		데이터형
교란지수	8개/day씩 총 2922개	변환	(23376, 1)

2) - 4. 결측치 처리

보간을 threshold=5로 진행하였으므로 여전히 결측치가 존재함. 따라서 22376개의 데이터 셋을 모두 검사하여 결측치가 존재하는 데이터는 모두 삭제함. (단, 삭제시 정답 데이터와 일대일 매핑하여 함께 삭제해야 함.)

```
def delete_nan(X, y):
    delete_idx = []

    for idx, X_ in enumerate(X):
        if np.isnan(X_).sum() != 0:
            delete_idx.append(idx)

    return np.delete(X,delete_idx, axis = 0), to_categorical(np.delete(y,delete_idx, axis = 0))

GI_X = np.concatenate([GGG_X, GGI_X], axis=2)
GJ_X = np.concatenate([GGG_X, GGJ_X], axis=2)
IJ_X = np.concatenate([GGI_X, GGJ_X], axis=2)

GIJ_X = np.concatenate([GGG_X, GGI_X, GGJ_X], axis=2)

# 조합 X
GGG_X, GGG_y = delete_nan(GGG_X, y)
GGI_X, GGI_y = delete_nan(GGI_X, y)
GGJ_X, GGJ_y = delete_nan(GGJ_X, y)

# 조합 O
GI_X, GI_y = delete_nan(GI_X, y)
GJ_X, GJ_y = delete_nan(GJ_X, y)
IJ_X, IJ_y = delete_nan(IJ_X, y)

GIJ_X, GIJ_y = delete_nan(GIJ_X, y)
```

입력 데이터 셋의 변화 : (22376, 180, 3) -> (22376-α, 180, 3)

2) - 5. 데이터 feature 추출

A.

위키피디아의 Kp 지수에 계산에 관한 설명

***"The maximum positive and negative deviations during the 3 hour period are added together to determine the total maximum fluctuation."*[2]**

구글 번역

총 최대 변동을 결정하기 위해 3시간 동안의 최대 양수 및 음수 편차를 합산합니다.

"변동" 이라는 단어에 초점을 맞춰 변동은 곧 변화율을 의미 180개의 시계열 데이터를 미분하기로 결정.
현재의 시점과 n분 뒤의 시점을 뺌
(미분에 정의에 의하면 간격인 h를 나눠줘야 하지만 모두 동일한 간격으로 설정되어 있으므로 나누지 않아도 무방함.) **=> gap 변수**

[Example] Gap=2인 경우 데이터 처리

원본 데이터

1	2	3	4	• • •	177	178	179	180

[M] 데이터

1	2	3	4	• • •	177	178	Gap

[N] 데이터

B.

180분의 데이터를 모두 사용하는 것과 시점이 많이 흐른 데이터를 없애는 것에 대해 어떤 것이 더 효율적인지 확인. **=> distance 변수**

A, B를 고려

```
G_diff_X = GGG_X[:,0:180-gap-distance,:] - GGG_X[:,gap:180-distance,:]
I_diff_X = GGI_X[:,0:180-gap-distance,:] - GGI_X[:,gap:180-distance,:]
J_diff_X = GGJ_X[:,0:180-gap-distance,:] - GGJ_X[:,gap:180-distance,:]

GI_diff_X = GI_X[:,0:180-gap-distance,:] - GI_X[:,gap:180-distance,:]
GJ_diff_X = GJ_X[:,0:180-gap-distance,:] - GJ_X[:,gap:180-distance,:]
IJ_diff_X = IJ_X[:,0:180-gap-distance,:] - IJ_X[:,gap:180-distance,:]

GIJ_diff_X = GIJ_X[:,0:180-gap-distance,:] - GIJ_X[:,gap:180-distance,:]
```

C. 평균, 최대, 최소, 표준편차 추출

distance와 gap을 고려하여 전처리한 이후 180개의 시계열 데이터에 대해 평균, 최대, 최소, 표준편차를 추출

```
def get_feature(X):
    feature = []

    for sample in X:
        tmp = sample[:,:].max(axis=0).tolist() + sample[:,:].min(axis=0).tolist() + sample[:,:].mean(axis=0).tolist() +
sample[:,:].std(axis=0).tolist()
        feature.append(tmp)

    return np.array(feature)

G_diff_feature_X = get_feature(G_diff_X)
I_diff_feature_X = get_feature(I_diff_X)
J_diff_feature_X = get_feature(J_diff_X)

GI_diff_feature_X = get_feature(GI_diff_X)
GJ_diff_feature_X = get_feature(GJ_diff_X)
IJ_diff_feature_X = get_feature(IJ_diff_X)

GIJ_diff_feature_X = get_feature(GIJ_diff_X)
```

2. 적용 알고리즘

2.1 적용 머신러닝 기법(Random Forest)

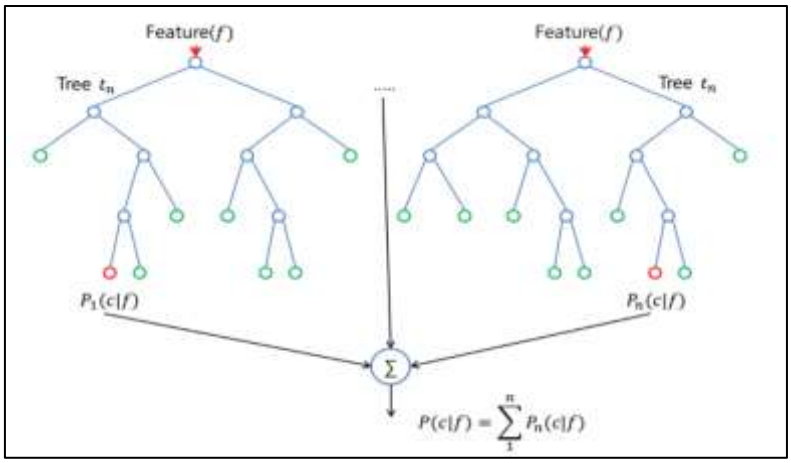

케라스에서 제공하는 Random Forest를 사용하였으며 파라미터는 default값을 사용함

2.2 입력 조합 설정

① 강릉(Bx, By, Bz)

② 이천(Bx, By, Bz)

③ 제주(Bx, By, Bz)

④ 강릉(Bx, By, Bz) + 이천(Bx, By, Bz)

⑤ 강릉(Bx, By, Bz) + 제주(Bx, By, Bz)

⑥ 이천(Bx, By, Bz) + 제주(Bx, By, Bz)

⑦ 강릉(Bx, By, Bz) + 이천(Bx, By, Bz) + 제주(Bx, By, Bz)

총 7개의 조합이 나올 수 있으며 해당 조합에 대해 모두 테스트

3. 모델 구성

케라스에서 제공하는 Random Forest 적용

```
def test_rf(X, y):
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.1, random_state=42)

    rf = RandomForestClassifier(random_state=0)
    rf.fit(X_train, y_train.argmax(axis=1))

    pred = rf.predict(X_test)

    return rf, accuracy_score(y_test.argmax(axis=1), pred)

rf = []
acc = []
for idx, name in enumerate(total_data.keys()):
    rf_, acc_ = test_rf(total_data[name][0], total_data[name][1])
    rf.append(rf_)
    acc.append(acc_)
    print("({}) 조합 {} Accuracy : {}%".format(idx, name, round(acc_, 4))
```

4. 모델 정확도(accuracy)

데이터 셋을 train 셋과 test 셋으로 나누어 train 셋으로 학습한 뒤 test 셋에 대한 Accuracy 측정

gap = 0 부터 48까지 증가시키며 7가지 입력 데이터 조합에 대해 test set Accuracy 측정

Gap=1		Gap=2		Gap=3		Gap=4		Gap=5	
ACC1	0.67167	ACC1	0.69031	ACC1	0.70168	ACC1	0.71669	ACC1	0.73169
ACC2	0.66424	ACC2	0.70068	ACC2	0.71526	ACC2	0.72692	ACC2	0.74344
ACC3	0.68938	ACC3	0.71778	ACC3	0.72564	ACC3	0.73744	ACC3	0.73875
ACC4	0.66477	ACC4	0.69684	ACC4	0.69891	ACC4	0.72944	ACC4	0.73616
ACC5	0.69531	ACC5	0.71575	ACC5	0.72782	ACC5	0.74454	ACC5	0.75151
ACC6	0.68983	ACC6	0.7067	ACC6	0.71662	ACC6	0.72705	ACC6	0.74491
ACC7	0.69873	ACC7	0.73044	ACC7	0.73414	ACC7	0.74683	ACC7	0.75581

Gap=39		Gap=40		Gap=41		Gap=42		Gap=43	
ACC1	0.84129	ACC1	0.83629	ACC1	0.8372	ACC1	0.83947	ACC1	0.83174
ACC2	0.8518	ACC2	0.85569	ACC2	0.84742	ACC2	0.85326	ACC2	0.84548
ACC3	0.82001	ACC3	0.82481	ACC3	0.81826	ACC3	0.8187	ACC3	0.82132
ACC4	0.8412	ACC4	0.84273	ACC4	0.83808	ACC4	0.84325	ACC4	0.84428
ACC5	0.83883	ACC5	0.83744	ACC5	0.83883	ACC5	0.84255	ACC5	0.83976
ACC6	0.84367	ACC6	0.84119	ACC6	0.8402	ACC6	0.84913	ACC6	0.84913
ACC7	0.85677	ACC7	0.86364	ACC7	0.86416	ACC7	0.86892	ACC7	0.86205

gap이 42이고 **⑦번 데이터 조합**일 때 ACC가 가장 높음.

distance = 0 부터 4까지 증가시키며 test set Accuracy 측정

distance=0		distance=2		distance=4	
ACC1	0.83947	ACC1	0.83129	ACC1	0.82901
ACC2	0.85326	ACC2	0.84402	ACC2	0.84014
ACC3	0.8187	ACC3	0.81346	ACC3	0.80952
ACC4	0.84325	ACC4	0.83549	ACC4	0.83394
ACC5	0.84255	ACC5	0.84069	ACC5	0.83744
ACC6	0.84913	ACC6	0.84764	ACC6	0.84169
ACC7	0.86892	ACC7	0.85579	ACC7	0.84672

distance가 올라갈 수록 정확도가 낮아짐. 즉, **180분 데이터 모두 사용**하는 것이 ACC가 가장 높음.

최종모델(Gap=42, distance=0, 데이터조합 ⑦번)

구분	정확도(Accuracy)	적용
train	100.000%	model=RandomForest metrics=Accuracy
test	86.892%	

5. 참고 문헌

[1] https://spaceweather.rra.go.kr/obsenv3.do

[2] https://en.wikipedia.org/wiki/K-index